Práctica 1: Fundamentos de Vectorización en x86: Extensiones Vectoriales, Vectorización Automática y Manual 30237 Multiprocesadores - Grado Ingeniería Informática Esp. en Ingeniería de Computadores

Jesús Alastruey Benedé y Víctor Viñals Yúfera Área Arquitectura y Tecnología de Computadores Departamento de Informática e Ingeniería de Sistemas Escuela de Ingeniería y Arquitectura Universidad de Zaragoza

Febrero-2024

Resumen

El objetivo de esta práctica es familiarizarse con las extensiones vectoriales AVX y AVX-512 de Intel. Analizaremos las instrucciones SIMD generadas por el compilador al vectorizar de forma automática un bucle sencillo. También estudiaremos el código generado al vectorizar un bucle de forma manual mediante intrínsecos. Por último, ejecutaremos las versiones escalar y vectorial del bucle y compararemos su rendimiento.




Figure 1: Operación vectorial¹

¹Stephen Blair-Chappell (Intel Compiler Labs). The significance of SIMD, SSE and AVX for Robust HPC Development.



Ficheros de trabajo

- p1.md y p1.pdf: ficheros en formatos markdown y pdf con el enunciado de la práctica.
- scale_shift.c: código C con dos versiones de un bucle, una vectorizable de forma automática (compilador):

```
for (unsigned int i = 0; i < LEN; i++)
   x[i] = alpha*x[i] + beta;</pre>
```

y otra vectorizada de forma manual (programador) mediante intrínsecos SSE:

```
valpha = _mm_set1_ps(alpha);
vbeta = _mm_set1_ps(beta);
for (unsigned int i = 0; i < LEN; i+= SSE_LEN)
{
    vX = _mm_load_ps(&x[i]);
    vX = _mm_mul_ps(valpha, vX);
    vX = _mm_add_ps(vX, vbeta);
    _mm_store_ps(&x[i], vA);
}</pre>
```

- precision.h: fichero donde se define
 - el tipo de dato real: float o double
 - el número de elementos procesados por cada instrucción vectorial para las extensiones vectoriales SSE,
 AVX y AVX-512
- dummy.c: contiene una función cuyo objetivo es forzar al compilador a generar código que ejecute el bucle de trabajo un número especificado de repeticiones.
- init_cpuname.sh: script que inicializa la variable CPU (export CPU=cpu_model), utilizada para organizar los resultados de los experimentos.
- comp.sh: script que compila versiones escalares y vectoriales del programa scale_shift.c. Soporta versiones recientes de los compiladores gcc, clang e icc (intel C compiler).

 Nota: compiladores disponibles en los sistemas del DIIS:

```
- gcc 12.2.1, gcc 11.2.0
```

- run.sh: script que ejecuta las compilaciones escalar y vectorial del programa de trabajo.
- sde.sh: script para ejecutar las compilaciones escalar y vectorial del programa de trabajo con la herramienta Intel SDE.
- comp.run.all.len.sh: script para compilar y ejecutar las versiones escalares y vectoriales del programa scale_shift.c con distintos tipos de datos y longitudes de los vectores de trabajo.

Trabajo previo

- 1. Requerimientos hardware y software:
 - CPU con soporte de la extensión vectorial AVX
 - SO Linux

Los equipos del laboratorio L0.04 y L1.02 cumplen los requisitos indicados. Puede trabajarse en dichos equipos de forma presencial y también de forma remota si hay alguno arrancado con Linux. Para saber qué máquinas de un laboratorio están accesibles de forma remota, ejecutar la siguiente orden en hendrix:

```
$ rcmds -f lab102 -s -- uptime
```

Puede cambiarse el nombre de laboratorio cuyos equipos se quieren inspeccionar. En la web de la asignatura se proporciona otro script que genera una lista de las direcciones IP y SO de las máquinas que están arrancadas en el L1.02.

- 2. Identificar la plataforma de trabajo (lab004, lab102, equipo propio):
 - a. Características de la plataforma de trabajo: CPU, sistema operativo, versión del compilador . . .
 - b. Detallar qué extensiones vectoriales soporta la CPU. Ayuda: consulta el fichero /proc/cpuinfo.

En caso de trabajar en un equipo del DIIS, para usar la reciente versión 12.2.1 del compilador gcc hay que editar el fichero oculto .software que está en vuestro \$HOME y añadir la palabra clave gcc. Este cambio tendrá efecto en los terminales que se abran a partir de ese momento. Para verificar la versión de gcc:

```
$ gcc -v
[...]
gcc versión 12.2.1 (GCC)
```

Nota: conviene señalar que cuando se hace login en Linux con el sistema gráfico por defecto, normalmente los terminales que se ejecutan no utilizan un login shell por defecto. Esto significa que muchas variables de entorno necesarias no se inicializan, por ejemplo, la que controla la versión de gcc. Esta incidencia se soluciona cambiando las preferencias del terminal para que por defecto utilice un login shell.

En gnome-terminal:

Menu->Edit->Preferences->Unnamed->Command:

- [x] Run command as a login shell
- 3. Inicializar la variable de entorno CPU. Se utiliza para organizar en directorios diferentes los experimentos realizados con distintos procesadores. Para ello hay que ejecutar:
 - \$ source ./init_cpuname.sh

Esta orden ejecuta el script en el shell existente, lo que permite que la variable creada por el script esté disponible después de que el script finalice su ejecución. Si se invoca el script directamente

\$./init_cpuname.sh

se ejecuta en otro shell, por lo que la variable de entorno no estará inicializada en el shell de trabajo.

Parte 1. Vectorización automática

En esta parte vamos a estudiar la capacidad para vectorizar bucles del compilador gcc. También analizaremos el rendimiento del código vectorizado.

- 1. Analiza y comprende el contenido de los ficheros scale_shift.c y comp.sh. scale_shift() es una operación que se utiliza para normalizar los datos que entrenan una red neuronal (batch normalization). También se utiliza en procesado de imagen. Hemos escogido un tamaño del vector que permite su almacenamiento en cache. De esta forma, los elementos de los vectores se leerán de memoria cache en lugar de memoria principal. comp.sh es un fichero para automatizar las tareas de compilación. Observa con detenimiento las opciones de compilación que especifican las extensiones vectoriales a utilizar.
- 2. Compila con gcc las distintas versiones escalares y vectoriales (avx, avx+fma, avx512) del programa en scale_shift.c:
 - \$./comp.sh

Observa los informes del compilador que se han generado en el directorio reports, en especial la información correspondiente al bucle interno en la función scale_shift()? ¿Ha vectorizado el bucle en scale_shift()?

3. Analiza los ficheros que contienen el ensamblador de los siguientes códigos escalares y vectoriales: esc.avx, vec.avx, vec.avxfma y vec.avx512. Busca las instrucciones correspondientes al cuerpo del bucle en la función scale_shift():

$$x[i] = alpha*x[i] + beta$$

Indica qué instrucciones se usan para:

- leer el vector $\mathbf{x}[]$ de memoria
- multiplicar y sumar
- escribir el vector resultado x[] en memoria

¿Cuántos elementos de cada vector se procesan en una iteración del bucle en ensamblador (esc.avx, vec.avx y vec.avx512)?

Sabiendo el tipo de dato procesado y su tamaño, ¿cuántos bytes del vector se procesan en una iteración del bucle en ensamblador (esc.avx, vec.avx y vec.avx512)?

¿Hay alguna diferencia entre las instrucciones AVX y AVX-512?

4. ¿Cuántas instrucciones se ejecutan en el bucle interno (esc.avx, vec.avx, vec.avxfma y vec.avx512)?

```
for (unsigned int i = 0; i < LEN; i++)
    x[i] = alpha*x[i] + beta</pre>
```

Por ejemplo, para la versión esc.avx:

$$ICOUNT = N \cdot LEN = 6 \cdot 1024 = 6144 \ instrucciones$$

siendo N el número de instrucciones del cuerpo del bucle (6) y LEN el número de elementos del vector (número iteraciones del bucle escalar, 1024).

Calcula la reducción en el número de instrucciones respecto la versión esc.avx.

versión	icount	$\mathrm{reducci\acute{o}n}(\%)$	reducción(factor)
esc.avx vec.avx vec.avxfma	6144	0	1.0
vec.avxiiia vec.avx512			

5. Ejecuta los programas compilados anteriormente:

\$./run.sh

Observa los ficheros de salida que se han generado en el directorio results, La columna Time muestra el tiempo medio de ejecución del bucle interno (kernel scale_shift), no el tiempo de todas sus ejecuciones. La columna TPE (tiempo por elemento) muestra el tiempo medio de ejecución por elemento (tiempo medio de ejecución dividido por la longitud de los vectores). Esta métrica permite comparar los rendimientos al ejecutar scale_shift con vectores de distinto tamaño.

¿Qué ocurre al ejecutar la versión vec.avx512?

\$./scale_shift.1k.single.vec.avx512.gcc

Para obtener más información de lo que ha ocurrido, carga en gdb el binario y el fichero core generado:

\$ gdb scale_shift.1k.single.vec.avx512.gcc core.xyz

Sustituye xyz por el identificador del proceso que ha generado el fichero core.

gdb nos mostrará la línea de código que ha provocado el error.

En caso de que no se haya generado fichero core, habilita su creación y vuelve a ejecutar:

- \$ ulimit -c unlimited
- \$./scale_shift.1k.single.vec.avx512.gcc

Para ver la última instrucción ejecutada:

- \$ (gdb) layout asm
- 6. A partir de los tiempos de ejecución obtenidos en el punto anterior, calcula las siguientes métricas para todas las versiones ejecutadas:
 - Aceleraciones (*speedups*) de las versiones vectoriales sobre sus escalares (vec.avx y vec.avxfma respecto esc.avx).
 - Rendimiento (R) en GFLOPS.
 - Rendimiento pico (R_{pico}) teórico de un núcleo (*core*), en GFLOPS. Para las versiones escalares, considerar que las unidades funcionales trabajan en modo escalar. Considerar asimismo la capacidad FMA de las unidades funcionales solamente para las versiones compiladas con soporte FMA.
 - Velocidad de ejecución de instrucciones (V_I), en Ginstrucciones por segundo (GIPS).

	versión	$\mathrm{tiempo}(\mathrm{ns})$	speed-up	R(GFLOPS)	$R_{\rm pico}({\rm GFLOPS})$	$V_{\rm I}({\rm GIPS})$
•	esc.avx		1.0			
	vec.avxfma					

Nota: $GFLOPS = 10^9 FLOPS$. $GIPS = 10^9 IPS$.

Comenta brevemente la tabla de resultados obtenidos (tiempo de ejecución, *speedup*, rendimiento, velocidad). ¿La velocidad de ejecución de instrucciones es un buen indicador de rendimiento? ¿Son consistentes los resultados (*checksums*) de las distintas versiones?

- 7. Optativo. Para obtener estadísticas de ejecución, ejecuta con perf los programas compilados:
 - \$./run.sh -s

- 8. Optativo. Usa la herramienta Intel Software Development Emulator (Intel SDE) [1] para obtener el número total de instrucciones ejecutadas por el bucle en la función scale_shift(). Para ello, recompila el fichero scale_shift.c especificando un valor más reducido para la constante NTIMES:
 - \$./comp.sh -T 10

Y ejecuta:

\$./sde.sh

Este script ejecuta bajo SDE las versiones esc.avx, vec.avx, vec.avxfma y vec.avx512 y genera informes con la cuenta de instrucciones correspondiente al bucle en la función scale_shift(). Por ejemplo, para la versión esc.avx:

```
BLOCK: 0 PC: 00000000004012d0 ICOUNT: 61440 EXECUTIONS: 10240 #BYTES: 22 %: 17.2 cumltv%: 17.2 FN: scale_shift
```

El número total de instrucciones ejecutadas (ICOUNT) es 61440. Se puede comprobar que coincide con el obtenido mediante la siguiente fórmula:

$$ICOUNT = N \cdot LEN \cdot NTIMES = 6 \cdot 1024 \cdot 10 = 61440$$

siendo N el número de instrucciones del cuerpo del bucle (6), LEN las iteraciones del bucle interno (1024) y NTIMES las iteraciones del bucle externo (10).

El número de ejecuciones del cuerpo del bucle interno (EXECUTIONS) es 10240, que coincide con el producto $LEN \cdot NTIMES = 1024 \cdot 10$.

El número de instrucciones de una ejecución del bucle interno se puede obtener dividiendo el número total de instrucciones ejecutadas por el número de veces que se ha ejecutado el bucle interno:

$$ICOUNT_{bucle} = \frac{ICOUNT}{NTIMES} = \frac{61440}{10} = 6144$$

Nota: verifica que las siguientes líneas de código estén comentadas para acelerar la ejecución:

```
ss_intr_SSE();
ss_intr_AVX();
```

Tras terminar este apartado, recompila con el valor original de FLOP_COUNT:

\$./comp.sh

Parte 2. Vectorización manual mediante intrínsecos

- 1. Observa el informe del compilador correspondiente a la compilación con soporte AVX. ¿Hay alguna indicación de que haya vectorizado el bucle en ss_intr_SSE()?
- 2. Escribe una nueva versión del bucle, ss_intr_AVX(), vectorizando de forma manual con intrínsecos AVX. Está el esqueleto de la función. El siguiente enlace puede ser de utilidad:

https://software.intel.com/sites/landingpage/IntrinsicsGuide/

- 3. Quita los comentarios de las llamadas a las funciones ss_intr_SSE() y ss_intr_AVX(). Recompila y ejecuta el código:
 - \$./comp.sh
 - \$./run.sh

Analiza el fichero que contiene el ensamblador de la versión AVX y busca las instrucciones correspondientes al bucle en ss_intr_AVX().

¿Hay alguna diferencia con las instrucciones correspondientes al bucle en scale_shift()?

¿Hay diferencia en el rendimiento de las funciones scale_shift() y ss_intr_AVX() (binario AVX)?

¿Hay diferencia en el rendimiento de las versiones vec.avx y vec.avxfma correspondientes al bucle ss_intr_AVX()? Compara las instrucciones generadas por el compilador para ambas versiones.

Apartados optativos

1. El flag -march=native genera flags de compilación para la máquina donde se está compilando. Para saber los flags que se generan:

```
$ gcc -march=native -E -v - </dev/null 2>&1 | grep cc1
```

Para compilar y ejecutar las versiones escalar y vectorial native:

- \$./comp.sh -n
- \$./run.sh -n

Compara el rendimiento de las versiones native (esc.native y vec.native) con el de las versiones avx (esc.avx y vec.avx).

- 2. Repite los puntos anteriores con vectores de precisión doble (double). El tipo de dato real se puede seleccionar como float o double mediante la variable p en el fichero comp.sh.
- 3. Repite los puntos anteriores con el compilador icc. Se recomienda que utilicéis una versión reciente, que podéis conseguir en el siguiente enlace:

https://software.intel.com/en-us/qualify-for-free-software/student

Es probable que haya que modificar los flags de compilación del fichero comp.sh.

- 4. Analiza el rendimiento y las aceleraciones del código procesando otros tamaños de vectores. Para ello, puedes ayudarte del script comp.run.all.len.sh.
- 5. Repetir la parte 1 en berlin (2xAMD EPYC 7313P), pilgor (2xHuawei Kunpeng 920-4826) o en otro sistema que disponga de un procesador con extensiones vectoriales.

Referencias

Bibliografía relacionada

- Stephen Blair-Chappell (Intel Compiler Labs). The significance of SIMD, SSE and AVX for Robust HPC Development.
- $\hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ http://stackoverflow.com/questions/8389648/how-do-i-achieve-the-theoretical-maximum-of-4-flops-per-cycle \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ http://stackoverflow.com/questions/8389648/how-do-i-achieve-the-theoretical-maximum-of-4-flops-per-cycle \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ http://stackoverflow.com/questions/8389648/how-do-i-achieve-the-theoretical-maximum-of-4-flops-per-cycle \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle? \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle \\ \hbox{-} How do I achieve the theoretical maximum of 4 FLOPs per cycle \\ \hbox{-} How do I achieve the theoretical maximum$
- Obtaining peak bandwidth on Haswell in the L1 cache: only getting 62%. http://stackoverflow.com/questions/25899395/obtaining-peak-bandwidth-on-haswell-in-the-l1-cache-only-getting-62
- Do FMA always produce the same result as a mul then add instruction? http://stackoverflow.com/questions/29086377/do-fma-fused-multiply-add-instructions-always-produce-the-same-result-as-a-mul